Tarea M20-CD- YAIR PALOMARES

Considere nuevamente la base de datos siguiente: FuelConsumptionCo2.xlsx

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
import os
import warnings
os.chdir("/Users/yair_/Downloads")
```

```
df = pd.read_excel("FuelConsumptionCo2.xlsx")
df.head()
```

	MODELYEAR	MAKE	MODEL	VEHICLECLASS	ENGINESIZE	CYLINDERS	TRANSMISSION	FUELTYPE	FUELCONSUMPTION_CITY	FUELCONSUMPTION_HWY	FUELCONS
0	2022	Acura	ILX	Compact	2.4	4	AM8	Z	9.9	7.0	
1	2022	Acura	MDX SH-AWD	SUV: Small	3.5	6	AS10	Z	12.6	9.4	
2	2022	Acura	RDX SH-AWD	SUV: Small	2.0	4	AS10	Z	11.0	8.6	
3	2022	Acura	RDX SH-AWD A-SPEC	SUV: Small	2.0	4	AS10	Z	11.3	9.1	
4	2022	Acura	TLX SH-AWD	Compact	2.0	4	AS10	Z	11.2	8.0	

Elimine las columnas de tipo categórico de la base de datos y verifique que no existan datos nulos que deban ser eliminados de manera previa al análisis.

```
df.dtypes
```

```
MODELYEAR                    int64
MAKE                        object
MODEL                       object
VEHICLECLASS                object
ENGINESIZE                 float64
CYLINDERS                    int64
TRANSMISSION                object
FUELTYPE                    object
FUELCONSUMPTION_CITY       float64
FUELCONSUMPTION_HWY        float64
FUELCONSUMPTION_COMB       float64
FUELCONSUMPTION_COMB_MPG     int64
CO2EMISSIONS                 int64
dtype: object
```

```
df.drop(columns = ["MAKE", "MODEL", "VEHICLECLASS", "TRANSMISSION", "FUELTYPE"], inplace=True)
df
```

	MODELYEAR	ENGINESIZE	CYLINDERS	FUELCONSUMPTION_CITY	FUELCONSUMPTION_HWY	FUELCONSUMPTION_COMB	FUELCONSUMPTION_COMB_MPG	CO2EM
0	2022	2.4	4	9.9	7.0	8.6	33	
1	2022	3.5	6	12.6	9.4	11.2	25	
2	2022	2.0	4	11.0	8.6	9.9	29	
3	2022	2.0	4	11.3	9.1	10.3	27	
4	2022	2.0	4	11.2	8.0	9.8	29	
...	...	...	...	...	...	...	...	
940	2022	2.0	4	10.7	7.7	9.4	30	
941	2022	2.0	4	10.5	8.1	9.4	30	
942	2022	2.0	4	11.0	8.7	9.9	29	
943	2022	2.0	4	11.5	8.4	10.1	28	
944	2022	2.0	4	12.4	8.9	10.8	26	

```
#Verificando si hay datos nulos en la base de datos
plt.figure(figsize=(20,6))
sns.heatmap(df.isnull(), yticklabels=False, cbar=False, cmap="viridis")
```

```
<Axes: >
```

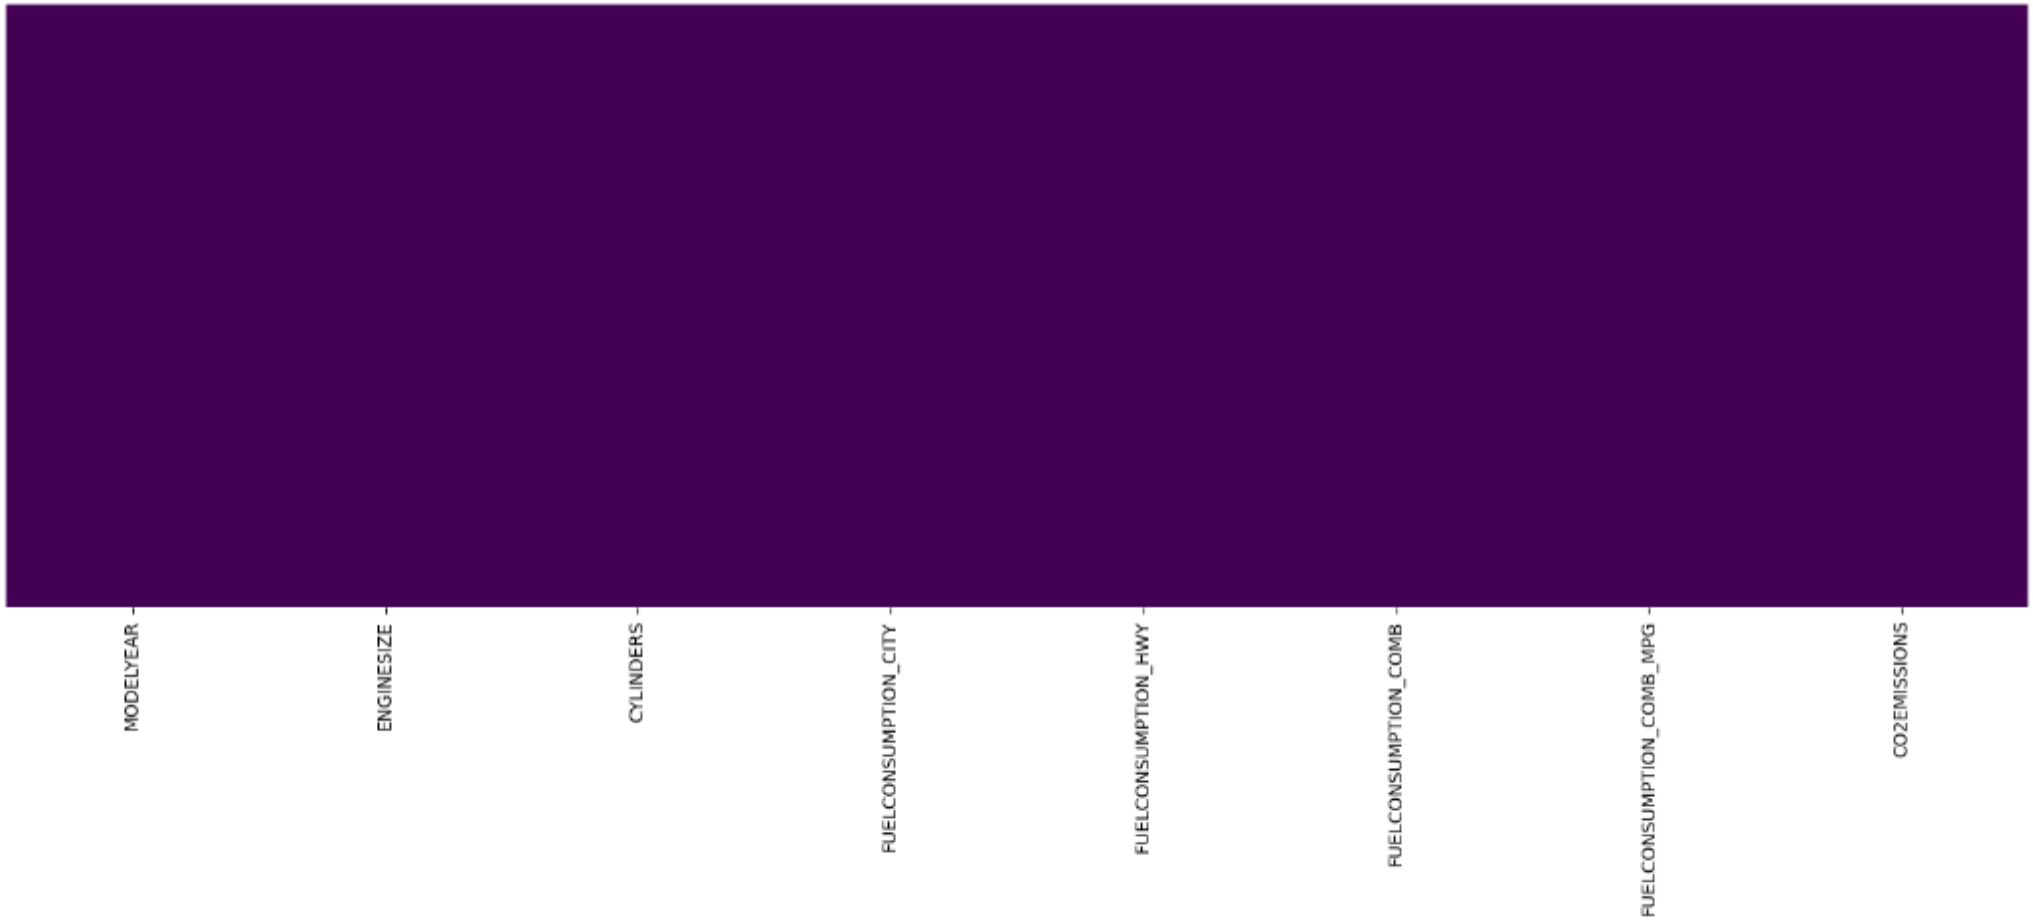

Realice un análisis de regresión múltiple para pronosticar la variable “CO2 EMISSIONS” con las variables remanentes. Obtenga los indicadores de bondad de ajuste correspondientes (R cuadrada, Error medio absoluto, etc.). Utilice los coeficientes resultantes y pronostique la primera observación de la base de prueba. ¿Coincide su resultado con aquel obtenido con la instrucción “predict”? Explique.

```
#Definición de variable dependiente y variables independientes
y = df["CO2EMISSIONS"]
x = df.drop(columns=["CO2EMISSIONS"])
```

```
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import Normalizer

#División en grupos de entrenamiento y de prueba.
x_train, x_test, y_train, y_test = train_test_split(x, y, test_size = 0.3, random_state = 1)

#Normalización de variables independientes
norm = Normalizer()
x_train_norm = norm.transform(x_train)
x_test_norm = norm.transform(x_test)

#Ajuste de modelo de regresión lineal múltiple.
linreg = LinearRegression()
linreg.fit(x_train_norm, y_train)
```

```
▾ LinearRegression
LinearRegression()
```

```python
#Cálculo de indicadores de la bondad de ajuste
from sklearn.metrics import r2_score
from sklearn import metrics

#Cálculo de predicciones
y_pred = linreg.predict(x_test_norm)

#Impresión de indicadores de bondad de ajuste
print("Valor de R cuadrada: ", r2_score(y_test, y_pred))
print("Error absoluto medio: ", metrics.mean_absolute_error(y_test, y_pred))
print("Error cuadrático medio: ", metrics.mean_squared_error(y_test, y_pred))
print("Raíz del error cuadrático medio: ", np.sqrt(metrics.mean_squared_error(y_test, y_pred)))
```

```
Valor de R cuadrada:  0.9785788322977577
Error absoluto medio:  5.980597587913508
Error cuadrático medio:  81.97577898244224
Raíz del error cuadrático medio:  9.054047657398444
```

```python
valor_1_pronostico = 673799.4287870198 + (-673344.34070171)*0.99987025 + (-1044.61786281)*0.00197798 + 9776.4470572*0.00296697 + (-8048.87207764)*0.0077
print("Resultado con la instrucción predict: ", y_pred[0])
print("Resultado utilizando los coeficientes: ", valor_1_pronostico)
```

```
Resultado con la instrucción predict:  317.7328212003922
Resultado utilizando los coeficientes:  317.73519217389605
```

El resultado si coincide, ya que la instrucción predict calcula el resultado de la función del modelo estadístico.

Repita el ejercicio 3 pero aplicando un modelo de regresión Ridge mediante el valor de Alpha óptimo.

```
#Definición de un rango de prueba para Alpha
alpha_range = 10.**np.arange(-5,5)
alpha_range

#Selección del Alpha óptimo
from sklearn.linear_model import RidgeCV
ridgeregcv = RidgeCV(alphas = alpha_range, scoring = "neg_mean_squared_error")
ridgeregcv.fit(x_train_norm, y_train)
print("Valor óptimo de alpha: "ridgeregcv.alpha_)
#Predicción mediante el mejor valor de alpha
y_pred = ridgeregcv.predict(x_test_norm)

#Impresión de indicadores de bondad de ajuste
print("Valor de R cuadrada: ", r2_score(y_test, y_pred))
print("Error absoluto medio: ", metrics.mean_absolute_error(y_test, y_pred))
print("Error cuadrático medio: ", metrics.mean_squared_error(y_test, y_pred))
print("Raíz del error cuadrático medio: ", np.sqrt(metrics.mean_squared_error(y_test, y_pred)))
```

```
1e-05
Valor de R cuadrada:  0.9778618048725993
Error absoluto medio:  6.357600243507036
Error cuadrático medio:  84.71974152202756
Raíz del error cuadrático medio:  9.204332758110583
```

Repita el ejercicio 3 pero aplicando un modelo de regresión Lasso mediante el valor de Alpha óptimo.

```
#Selección del valor óptimo de alpha para la regresión Lasso
from sklearn.linear_model import LassoCV
lassoregcv = LassoCV(n_alphas=100, random_state=1)
lassoregcv.fit(x_train_norm, y_train)
print("Valor óptimo de alpha: ",lassoregcv.alpha_)
#Predicción mediante regresión de Lasso con un Alpha óptimo
y_pred = lassoregcv.predict(x_test_norm)

#Impresión de indicadores de bondad de ajuste
print("Valor de R cuadrada: ", r2_score(y_test, y_pred))
print("Error absoluto medio: ", metrics.mean_absolute_error(y_test, y_pred))
print("Error cuadrático medio: ", metrics.mean_squared_error(y_test, y_pred))
print("Raíz del error cuadrático medio: ", np.sqrt(metrics.mean_squared_error(y_test, y_pred)))
```

```
Valor óptimo de alpha:  0.00022466802745368518
Valor de R cuadrada:  0.9775593566434242
Error absoluto medio:  6.404277182732142
Error cuadrático medio:  85.8771681167458
Raíz del error cuadrático medio:  9.266993477754573
```

¿Cuál de los 3 modelos de regresión resultó ser el mejor? Explique a detalle.

El modelo que se ajustó de mejor manera fue el modelo de regresión lineal múltiple. Para los modelos de regresión Ridge y Lasso, el valor óptimo de alpha que arrojaban de acuerdo al rango de experimentación siempre tendía a que fuera cero, esto significa no había sobre ajuste y no era necesario regularizar el modelo de regresión, ya que todas las variables independientes del análisis aportan en el comportamiento de las emisiones de CO2.